CESI
ÉCOLE D'INGÉNIEURS

BLOC STOCKAGE ET BIGDATA

PGE A4 FISA/A3 FISE Big data 26 27 ETU octobre

Projet

INTRODUCTION

Le potentiel énorme associé aux données médicales a conduit le secteur de la santé à une transformation importante et rapide. Ainsi, les exigences de mise en place d'améliorations sont de plus en plus significatives. Pour progresser dans la bonne voie, les praticiens (médecins, personnel infirmier) et les administrateurs d'établissements doivent pouvoir accéder directement aux informations exploitables dans les données médicales, afin d'améliorer leurs performances et la qualité des soins de manière mesurable. La demande en matière d'informations exploitables découlant des données médicales intégrées se fait pressante. Les données relatives à l'affluence des patients, aux dossiers médicaux, au suivi des services, aux durées des cycles et sur la rentabilité des établissements recèlent d'importantes informations encore inexploitées, qui attendent d'être découvertes.

Pour toutes ces raisons, le secteur doit investir dans le développement des systèmes informatiques évolutifs, qui comprennent un ensemble d'outils et de mécanismes pour charger, extraire et traiter les données médicales. Ces systèmes parient sur la puissance de traitement parallèle et des ressources distribuées pour effectuer des transformations et des analyses complexes, pour optimiser la prise de décisions. Ainsi, pour rendre cette analyse possible, les entreprises ont besoin de nouvelles données agrégées, consolidées, historiques et synthétisées selon plusieurs axes. Le besoin d'une nouvelle architecture, qui stocke et traite ce type de données a émergé du domaine de la BI et a donné naissance aux infrastructures d'entreposage de données (datawarehouse et datamart). Ces dernières sont des structures qui intègrent des données pour l'analyse et la présentation d'informations pertinentes.

Par ailleurs, le développement d'un système décisionnel évolutif fait face à une série de défis techniques dont le paradigme des données massives (Big Data). Tout d'abord, en raison de la variété et du volume des sources de données disparates, il est difficile de recueillir et d'intégrer des données à partir d'emplacements distribués. Deuxièmement, les systèmes de données volumineux doivent stocker et gérer l'ensemble des données massives et hétérogènes recueillies et assurer une certaine performance en termes d'accès rapide, d'évolutivité et de protection de la vie privée.

SUJET

Énoncé

PROJET CLOUD HEALTHCARE UNIT

À l'instar de l'ensemble du secteur hospitalier français, le groupe **CHU** a engagé une transformation digitale majeure de son système d'information. Dans ce cadre, votre équipe est sollicitée pour concevoir et implémenter un **entrepôt de données décisionnel (EDD)** qui permettra au groupe d'exploiter la volumétrie considérable de données générées par ses systèmes opérationnels de gestion des soins, ainsi que par les fichiers de données distribués accessibles via **protocole FTP**.

L'objectif principal est de fournir une plateforme analytique unifiée capable de répondre à la diversité des besoins d'accès, d'exploration et de visualisation des données exprimés par les différentes catégories d'utilisateurs. Pour cela, le groupe CHU attend :

- Une **solution d'architecture complète** (modèles conceptuel, logique et physique) permettant l'extraction, la transformation, le chargement **(ETL)** et le stockage des données dans un schéma décisionnel optimisé, en vue de leur exploration et visualisation selon différents axes d'analyse.
- Une **solution d'intégration de données hétérogènes** (bases relationnelles, fichiers plats CSV, fichiers open data) dans une source unique persistante, cohérente et gouvernée.
- Un **recensement structuré des besoins utilisateurs** par profil (praticiens, direction d'établissement) en termes d'analyse des données relatives au suivi des patients, à l'activité hospitalière, aux indicateurs de mortalité et à la satisfaction des usagers, à l'échelle nationale et sur le long terme.
- Des **préconisations argumentées** concernant l'outillage d'intégration (ETL), de stockage (SGBD analytique ou moteur distribué), de visualisation (outil BI) et de sécurisation des données, afin de favoriser une prise de décision éclairée et conforme aux exigences réglementaires.

Cette étude s'inscrit dans les défis spécifiques à la santé numérique. Toute solution proposée devra satisfaire les exigences non fonctionnelles suivantes : **ratio coût-efficacité**, **sécurité des données de santé** (conformité RGPD, certification HDS), **élasticité** et **scalabilité** de l'infrastructure.

Les données

Les sources de données mises à disposition sont issues des systèmes d'information opérationnels du groupe HCG et couvrent plusieurs années d'historique. Compte tenu de la **sensibilité réglementaire** des informations traitées (données à caractère personnel de santé au sens du **RGPD**), l'infrastructure retenue devra être conforme aux exigences d'**hébergement de données de santé (HDS)** et soumise à une gouvernance rigoureuse des données.

Les quatre sources de données disponibles sont les suivantes :

- **Source 1 — Base de données PostgreSQL opérationnelle** : gestion des actes **médico-administratifs** des patients (admissions, consultations, diagnostics, séjours hospitaliers). Le schéma relationnel de cette base sera fourni en annexe et devra être analysé avant toute modélisation dimensionnelle.
- **Source 2 — Fichiers CSV** : données exportées relatives à la gestion administrative des établissements hospitaliers de France (capacités, certifications, localisation géographique par code **INSEE/FINESS**). Ces fichiers constituent une source de données de référence (*référentiel établissements*), et non une base de données à proprement parler.
- **Source 3 — Fichiers plats accessibles via FTP** : notes de satisfaction émises par des patients sur différents établissements de santé. Le format exact (CSV, JSON), la fréquence de mise à jour et la volumétrie estimée sont à préciser lors de la phase de cadrage.
- **Source 4 — Fichiers plats accessibles via FTP** : données issues du **répertoire national des décès en France (source INSEE)**. Ces données constituent une source *open data* à intégrer comme dimension d'analyse de la mortalité.

Besoins utilisateurs

Une première consultation a permis de mettre en évidence le type d'analyses souhaitées par les utilisateurs :

- Taux de consultation des patients dans un établissement X sur une période de temps Y
- Taux de consultation des patients par rapport à un diagnostic X sur une période de temps Y
- Taux global d'hospitalisation des patients dans une période donnée Y
- Taux d'hospitalisation des patients par rapport à des diagnostics sur une période donnée
- Taux d'hospitalisation par sexe, par âge
- Taux de consultation par professionnel
- Nombre de décès par localisation (région) et sur l'année 2019 (optionnel)
- Taux global de satisfaction par région sur l'année 2020 (optionnel)

Les étapes du projet

Les phases du projet sont structurées selon une approche itérative, chaque phase alimentant la suivante :

- **Phase 1 , Cadrage et Architecture** : analyse des sources de données, choix de l'architecture cible (paradigme Lakehouse 3 couches : Bronze/Silver/Gold) et de la stack technologique (ETL, SGBD analytique, outil BI), identification des contraintes réglementaires (RGPD, HDS, CNIL), définition du plan de gouvernance des données.
- **Phase 2 , Modélisation Conceptuelle et Logique** : conception du modèle dimensionnel en **schéma en étoile** (approche Kimball), identification des tables de faits (Consultations, Hospitalisations, Décès, Satisfaction) et des dimensions (Temps, Établissement, Patient anonymisé, Diagnostic, Professionnel, Région INSEE), spécification des jobs ETL.
- **Phase 3 , Implémentation Physique** : création des tables, chargement des données, partitionnement et indexation adaptés au moteur retenu, tests de qualité des données (complétude, cohérence, unicité).
- **Phase 4 , Exploitation, Performance et Visualisation** : optimisation des requêtes analytiques, benchmarking des temps de réponse (avant/après optimisation), développement du tableau de bord décisionnel et du storytelling.

Les grandes phases envisagées du projet sont les suivantes :

1. Etude de l'architecture à mettre en place
2. Modélisation conceptuelle des données
3. Implémentation physique des données
4. Exploitation, mesure de performance, optimisation

Mise en oeuvre

Ce projet est à réaliser en groupe de 3 élèves (à défaut 4).

Vous disposez chacun d'un environnement virtualisé avec les outils nécessaires et avec suffisamment de ressources pour réaliser tous les traitements attendus.

A chaque étape, pensez à analyser les tâches qui peuvent être parallélisées et à la manière de synchroniser les données entre vous pour optimiser le travail de groupe.

Il s'agit d'un projet fil rouge couvrant l'ensemble du bloc. Les 4 boucles qui la composent sont contextualisées au projet. Tout ce que vous allez étudier et réaliser dans ces boucles fera avancer le projet.

Livrables attendus

- **Livrable 1, Référentiel de Données et Architecture** *(Format : Rapport écrit)*

  Ce livrable comprend :

  - Le **modèle conceptuel et logique** du schéma décisionnel (schéma en étoile documenté avec dictionnaire de données complet : noms des tables, attributs, types, cardinalités, clés primaires et étrangères).
  - La **description détaillée de l'architecture cible** : couches Bronze/Silver/Gold, flux de données de bout en bout, technologies retenues et justification des choix (ETL : ex. Talend / Apache NiFi / dbt ; stockage : ex. PostgreSQL / Hive / BigQuery ; BI : ex. Power BI / Metabase / Apache Superset).
  - Les **spécifications fonctionnelles des jobs ETL** : sources, règles de transformation, gestion des valeurs nulles et des doublons, gestion des erreurs et rejets, fréquence d'exécution.
  - Le **plan de gouvernance des données** : conformité RGPD (anonymisation, pseudonymisation), conformité HDS, rôles et droits d'accès, traçabilité des flux.

- **Livrable 2, Implémentation Physique et Évaluation de Performance** *(Format : Rapport + archive ZIP)*

  Ce livrable comprend :

  - Les **scripts SQL de création des tables** (DDL) et de **chargement des données** (DML), commentés et versionnés (Git recommandé), incluant la gestion des contraintes d'intégrité référentielle.
  - Les **scripts de partitionnement et d'indexation**, avec justification explicite de la stratégie retenue en fonction du moteur de stockage choisi (ex. : partitionnement par date en PostgreSQL ou par région en Hive ; notion de *buckets* propre à Hive/Spark uniquement).
  - Un **rapport de qualité des données intégrées** : taux de complétude par attribut, cohérence référentielle (codes FINESS), détection et traitement des doublons.
  - Un **jeu de requêtes de benchmark** représentatives des cas d'usage métier identifiés (minimum 5 requêtes couvrant les indicateurs définis dans les besoins utilisateurs).
  - Des **graphiques comparatifs des temps de réponse** (avant/après partitionnement et indexation) avec analyse et interprétation des résultats.

- **Livrable 3, Présentation des Résultats et Storytelling** *(Format : Soutenance orale 20 min + 10 min questions/réponses)*

  La soutenance doit refléter l'interprétation des résultats d'analyse à travers un **tableau de bord interactif**. Le groupe devra construire un **récit structuré** (*data storytelling*) fondé sur les résultats des requêtes analytiques, articulé autour des indicateurs métier définis, et adressé explicitement aux deux profils d'utilisateurs (praticiens et direction). Ce récit s'appuiera sur des graphiques, des cartes géographiques et des tableaux de synthèse pour informer et orienter la prise de décision.

  La présentation couvrira les aspects suivants :

- **Méthodologie** : présentation des choix d'architecture (Lakehouse, Kimball), des outils ETL et BI retenus, avec justification de chaque décision technique.
- **Modélisation et implémentation** : synthèse du schéma décisionnel, des règles de transformation ETL et des stratégies d'optimisation appliquées.
- **Restitution analytique et storytelling** : présentation des tableaux de bord, narration des résultats clés (indicateurs d'hospitalisation, de mortalité, de satisfaction), mise en évidence des insights actionnables pour les décideurs.
- **Démonstration technique live** : navigation dans le tableau de bord, exécution d'une requête en direct, illustration des performances obtenues.
- **Recommandations** : perspectives d'évolution du système (nouvelles sources de données, intégration de modèles prédictifs, mise en conformité continue avec le RGPD).