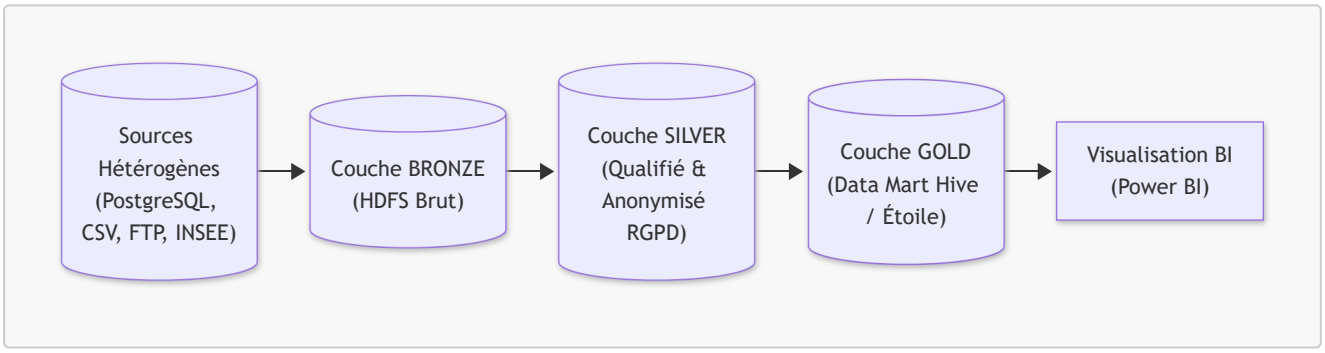
ÉCOLE D'INGÉNIEURS CESI

BLOC STOCKAGE ET BIG DATA — A4 FISA

LIVRABLE 1

RÉFÉRENTIEL DE DONNÉES ET ARCHITECTURE

Conception de l'Entrepôt de Données Décisionnel (EDD) du Groupe CHU (Cloud Healthcare Unit)



Membres du Groupe Projet :
Ulysse • Quentin • Jason

Sommaire

- 1. Introduction & Cadrage Métier du Projet CHU
  - 1.1. Contexte et Objectifs de la Transformation Digitale
  - 1.2. Inventaire et Qualification des 4 Sources de Données
  - 1.3. Recensement Structuré des Besoins Utilisateurs par Profil
    - A. Profil 1 : Praticiens (Médecins, Chefs de service, Personnel infirmier)
    - B. Profil 2 : Direction d'Établissement (Administrateurs, Contrôle de gestion, Qualité)
- 2. Architecture Cible Décisionnelle (Paradigme Lakehouse)
  - 2.1. Architecture 3 Couches : Bronze, Silver, Gold (Médaillon)
  - 2.2. Schéma Global des Flux de Données de Bout en Bout
  - 2.3. Préconisations et Justification de la Stack Technologique
    - A. Brique d'Intégration (ETL / ELT)
    - B. Brique de Stockage et Moteur Analytique
    - C. Brique de Visualisation (Business Intelligence)
- 3. Modélisation Conceptuelle et Logique du Schéma Décisionnel
  - 3.1. Méthodologie retenue : Approche Kimball (Constellation d'Étoiles)
  - 3.2. Modèle Logique Global (Schéma en Constellation d'Étoiles)
  - 3.3. Dictionnaire de Données Complet
    - A. Tables de Dimensions (Axes d'Analyse)
      - 1. Table `DIM_TEMPS` (Calendrier unique partagé)
      - 2. Table `DIM_LOCALISATION_INSEE` (Référentiel Géographique & Régions)
      - 3. Table `DIM_ETABLISSEMENT` (Hôpitaux et structures de soins — Source 2)
      - 4. Table `DIM_PATIENT` (Patient anonymisé — Sources 1 & 4)
      - 5. Table `DIM_DIAGNOSTIC` (Pathologies — Source 1)
      - 6. Table `DIM_PROFESSIONNEL` (Praticiens et soignants — Source 1)
    - B. Tables de Faits (Mesures et Événements)
      - 1. Table `FAIT_CONSULTATIONS` (Source 1 + Source 2)
      - 2. Table `FAIT_HOSPITALISATIONS` (Source 1 + Source 2)
      - 3. Table `FAIT_SATISFACTION` (Source 3 + Source 2)
      - 4. Table `FAIT_DECES` (Source 4 : Open Data INSEE)
  - 3.4. Matrice de Couverture des Indicateurs Métiers
- 4. Spécifications Fonctionnelles des Jobs ETL
  - 4.1. Architecture d'Alimentation et Ordonnancement
  - 4.2. Règles de Transformation, Formatage et Enrichissement
  - 4.3. Gestion des Valeurs Nulles, des Doublons, des Erreurs et des Rejets
  - 4.4. Planification et Fréquence d'Exécution des Flux
- 5. Plan de Gouvernance des Données et Sécurité (RGPD & HDS)
  - 5.1. Conformité RGPD : Minimisation, Pseudonymisation et Anonymisation
  - 5.2. Conformité HDS (Hébergeur de Données de Santé) et Sécurité Infrastructure
  - 5.3. Gestion des Rôles et Droits d'Accès (Matrice RBAC)
  - 5.4. Traçabilité des Flux (Data Lineage) et Cycle de Vie des Données
- Conclusion

1. Introduction & Cadrage Métier du Projet CHU

1.1. Contexte et Objectifs de la Transformation Digitale

Dans le cadre de la modernisation du secteur hospitalier français, le groupe **CHU (Cloud Healthcare Unit)** souhaite valoriser le volume massif de données générées par les systèmes d'information opérationnels du groupe **HCG** ainsi que par des sources externes (référentiels nationaux et fichiers distribués via FTP).

L'objectif de ce premier livrable est de définir l'architecture complète et le référentiel de données d'un **Entrepôt de Données Décisionnel (EDD)** unifié, permettant de :

- Centraliser et croiser des sources de données fortement hétérogènes (bases SQL, fichiers plats CSV/JSON, Open Data INSEE).
- Répondre aux besoins analytiques de deux grands profils d'utilisateurs : les **Praticiens** (médecins, cadres infirmiers) et la **Direction d'établissement** (administrateurs, décideurs).
- Garantir un haut niveau de **performance analytique (OLAP)**, d'**élasticité**, un excellent **ratio coût-efficacité**, ainsi qu'une conformité stricte au **RGPD** et à la certification **HDS (Hébergeur de Données de Santé)**.

1.2. Inventaire et Qualification des 4 Sources de Données

L'audit initial met en évidence **4 sources de données disparates** couvrant plusieurs années d'historique :

Réf.	Source de Données	Format & Protocole	Nature des Données	Volumétrie & Vélocité	Sensibilité RGPD / HDS
Source 1	**Base opérationnelle PostgreSQL (HCG)**	Relationnel SQL (OLTP)	Actes médico-administratifs : admissions, consultations, diagnostics, séjours hospitaliers, patients, professionnels.	Élevée (Plusieurs années d'historique transactionnel)	**Critique (Art. 9 RGPD)** : Données médicales et identifiantes patients.
Source 2	**Référentiel Établissements**	Fichiers plats **CSV** (Export local)	Gestion administrative des hôpitaux de France : numéro FINESS, capacités, certifications, code INSEE / localisation.	Faible à Moyenne (Référentiel statique / mise à jour périodique)	**Aucune** (Données administratives publiques d'établissements).
Source 3	**Enquêtes de Satisfaction**	Fichiers plats **CSV / JSON** via **FTP**	Notes de satisfaction émises par les usagers par établissement de santé et par période (ex: année 2020).	Moyenne (Collecte périodique par campagnes)	**Modérée** : Vérifier l'absence de données nominatives dans les commentaires.
Source 4	**Répertoire National des Décès (INSEE)**	Fichiers plats **CSV** Open Data via **FTP**	Décès enregistrés en France (sexe, date de naissance, date et commune/région INSEE de décès, notamment 2019).	Élevée (~600 000 lignes / an en France)	**Faible (Open Data)** : Données publiques de personnes décédées, mais à agréger par région.

1.3. Recensement Structuré des Besoins Utilisateurs par Profil

Afin de concevoir un modèle dimensionnel pertinent, nous avons segmenté les besoins analytiques selon les deux catégories d'utilisateurs cibles :

A. Profil 1 : Praticiens (Médecins, Chefs de service, Personnel infirmier)

- **Objectif métier :** Suivre la pathologie des patients, évaluer la charge de travail médicale par spécialité/professionnel et adapter les protocoles de soins selon le profil démographique (âge, sexe) et épidémiologique.
- **Indicateurs (KPI) attendus :**
  - **KPI-P1 :** Taux et volume de consultation des patients par rapport à un **diagnostic *X*** sur une **période de temps *Y***.
  - **KPI-P2 :** Taux et volume d'hospitalisation des patients par rapport à des **diagnostics** sur une **période donnée**.
  - **KPI-P3 :** Taux d'hospitalisation ventilé par **sexe** et par **tranche d'âge**.
  - **KPI-P4 :** Taux et volume de consultation par **professionnel de santé** (et par spécialité).
  - **KPI-P5 :** Nombre de **décès** par localisation (**région INSEE**) et par période (focus année 2019).

B. Profil 2 : Direction d'Établissement (Administrateurs, Contrôle de gestion, Qualité)

- **Objectif métier :** Piloter l'affluence hospitalière, optimiser le taux d'occupation des lits, comparer la performance entre établissements/régions et mesurer la qualité perçue par les usagers.
- **Indicateurs (KPI) attendus :**
  - **KPI-D1 :** Taux de consultation des patients dans un **établissement *X*** sur une **période de temps *Y***.
  - **KPI-D2 :** Taux global d'hospitalisation des patients sur une **période donnée *Y*** (et durée moyenne de séjour).
  - **KPI-D3 :** Taux global de **satisfaction des usagers** par établissement et par **région** (focus année 2020).

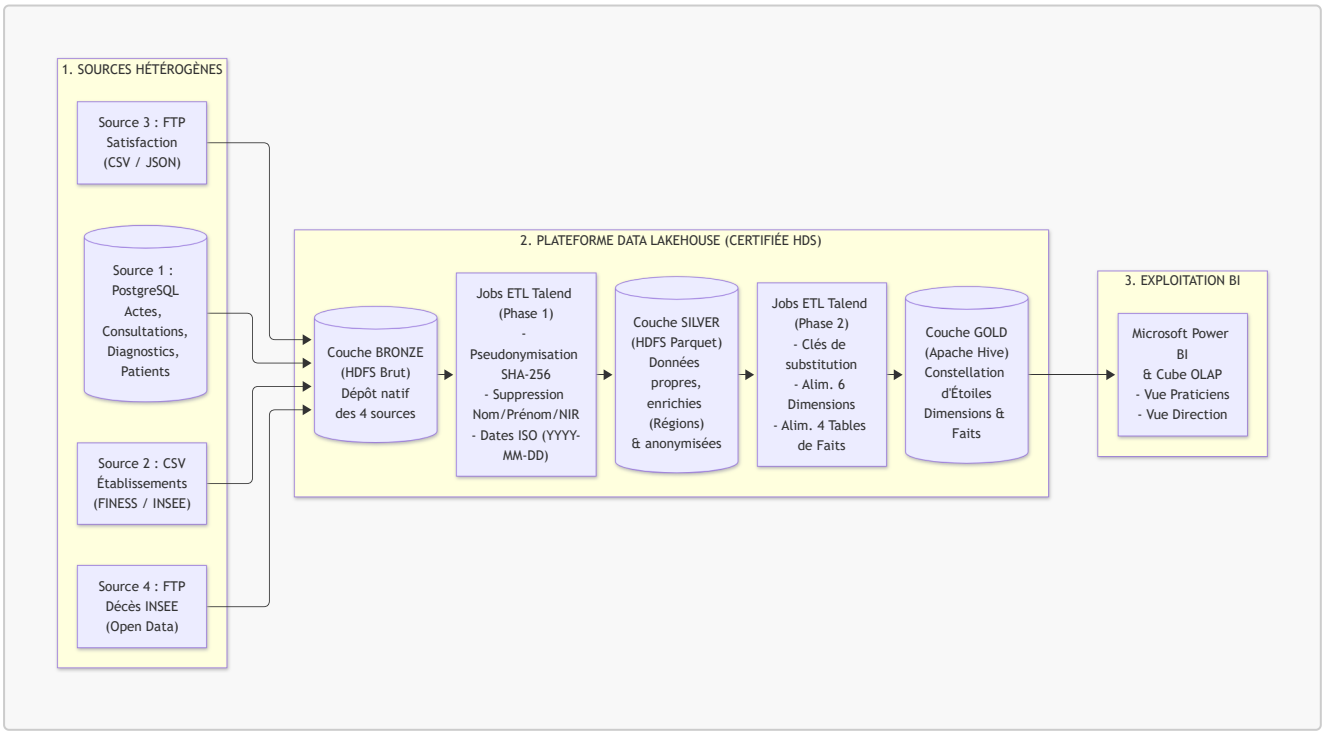
2. Architecture Cible Décisionnelle (Paradigme Lakehouse)

2.1. Architecture 3 Couches : Bronze, Silver, Gold (Médaillon)

Pour concilier la variété des sources (SQL, CSV, FTP) avec la rigueur d'un entrepôt décisionnel gouverné, nous retenons une architecture **Data Lakehouse en 3 couches (Architecture Médaillon)** déployée sur un cluster distribué **Cloudera Hadoop (HDFS + Apache Hive)** selon une logique **ELT / ETL hybride** :

1. **Couche BRONZE (Zone Brute / *Raw Ingestion Zone* — HDFS) :**
   - **Rôle :** Réceptionner à l'identique les extractions brutes issues de PostgreSQL, des fichiers CSV locaux et des serveurs FTP (Satisfaction et Décès INSEE).
   - **Caractéristique :** *Schema-on-Read*. Conservation de l'historique brut en format natif horodaté pour permettre le rejeu en cas d'évolution des règles métiers. Accès strictement interdit aux utilisateurs finaux (chiffrement disque actif).
2. **Couche SILVER (Zone Qualifiée & Anonymisée / *Trusted Zone* — HDFS Parquet) :**
   - **Rôle :** Stocker les données nettoyées, dédoublonnées, typées (dates converties au standard ISO `YYYY-MM-DD`), enrichies (correspondance Code INSEE / FINESS → Région) et **anonymisées/pseudonymisées conformément au RGPD**.
   - **Caractéristique :** Fichiers stockés au format colonnaire compressé **Apache Parquet**, garantissant une lecture rapide et l'absence totale de données nominatives directes.
3. **Couche GOLD (Zone Décisionnelle / *Curated Data Mart* — Apache Hive / SGBD Analytique) :**
   - **Rôle :** Exposer le **Modèle Dimensionnel en Étoile (Constellation Kimball)** composé des Tables de Dimensions et des Tables de Faits agrégées, partitionnées et indexées.
   - **Caractéristique :** *Schema-on-Write*. Alimente directement l'outil de Business Intelligence (**Microsoft Power BI**) pour les tableaux de bord des praticiens et de la direction.

2.2. Schéma Global des Flux de Données de Bout en Bout



2.3. Préconisations et Justification de la Stack Technologique

Afin de respecter les exigences non fonctionnelles (**ratio coût-efficacité**, **sécurité RGPD/HDS**, **élasticité** et **scalabilité**), nous avons comparé les solutions du marché pour chaque brique de l'architecture :

A. Brique d'Intégration (ETL / ELT)

Outil évalué	Avantages	Inconvénients	Choix & Justification
Talend Open Studio for Big Data	• Connecteurs natifs PostgreSQL, FTP, CSV, JSON, HDFS et Hive. • Composant `tMap` idéal pour les jointures FINESS/INSEE et l'anonymisation. • Génération de code Java/MapReduce sans coût de licence.	• Interface lourde en mémoire sur le poste développeur.	**RETENU** Excellent ratio coût-efficacité (Open Source), maîtrise rapide et gestion native des rejets et de la qualité des données.
Apache NiFi	• Excellent pour le routage de flux en temps réel (Streaming).	• Moins adapté aux transformations relationnelles complexes et jointures multi-sources en étoile.	Écarté (Utilisé uniquement en complément si flux temps réel futur).
dbt (data build tool)	• Parfait pour les transformations SQL dans l'entrepôt (T de l'ELT).	• Ne gère pas l'extraction depuis FTP/CSV ni l'anonymisation avant chargement.	Écarté pour l'ingestion initiale.
Python	• Flexibilité totale : gestion de tous les types de fichiers. • Adapté à toutes les étapes de la chaîne de traitement (Bronze, Silver, Gold).	• Nécessite de maintenir du code source. • Gestion manuelle des exceptions et des rejets.	**RETENU** Idéale pour orchestrer les pipelines personnalisés et couvrir le cycle complet du nettoyage à l'agrégation.

B. Brique de Stockage et Moteur Analytique

Outil évalué	Avantages	Inconvénients	Choix & Justification
HDFS + Apache Hive (avec stockage Parquet)	• Scalabilité horizontale (*Scale-out*) sur cluster. • Tolérance aux pannes (réplication x3). • Requêtage SQL standard (HiveQL) avec **partitionnement** et **bucketing**.	• Latence légèrement supérieure sur de très petits volumes si non optimisé (Tez/Spark requis).	**RETENU (Cible Big Data)** Permet de gérer à la fois le Data Lake (Bronze/Silver sur HDFS) et le Data Warehouse (Gold sous Hive). *(Compatible avec une implémentation PostgreSQL analytique partitionnée en environnement restreint).*
Google BigQuery / Snowflake	• Serverless ultra-rapide et élastique.	• Coût facturé à la requête et contraintes fortes de souveraineté Cloud Act / HDS.	Écarté (Risque budgétaire et réglementaire HDS).

C. Brique de Visualisation (Business Intelligence)

Outil évalué	Avantages	Inconvénients	Choix & Justification
Microsoft Power BI	• Connecteurs natifs Hive / PostgreSQL. • Moteur colonnaire en mémoire (*VertiPaq*) ultra-rapide. • Gestion fine de la sécurité par profil (**RLS - Row-Level Security** : Praticiens vs Direction).	• Licence Pro requise pour le partage Cloud, mais gratuit en version Desktop pour la maquette.	**RETENU** Ergonomie supérieure pour le *Data Storytelling*, cartes géographiques natives par région INSEE et filtrage dynamique.
Apache Superset / Metabase	• Open Source et léger en mode Web.	• Moins riche pour la modélisation DAX et le storytelling avancé.	Solution de repli secondaire.

3. Modélisation Conceptuelle et Logique du Schéma Décisionnel

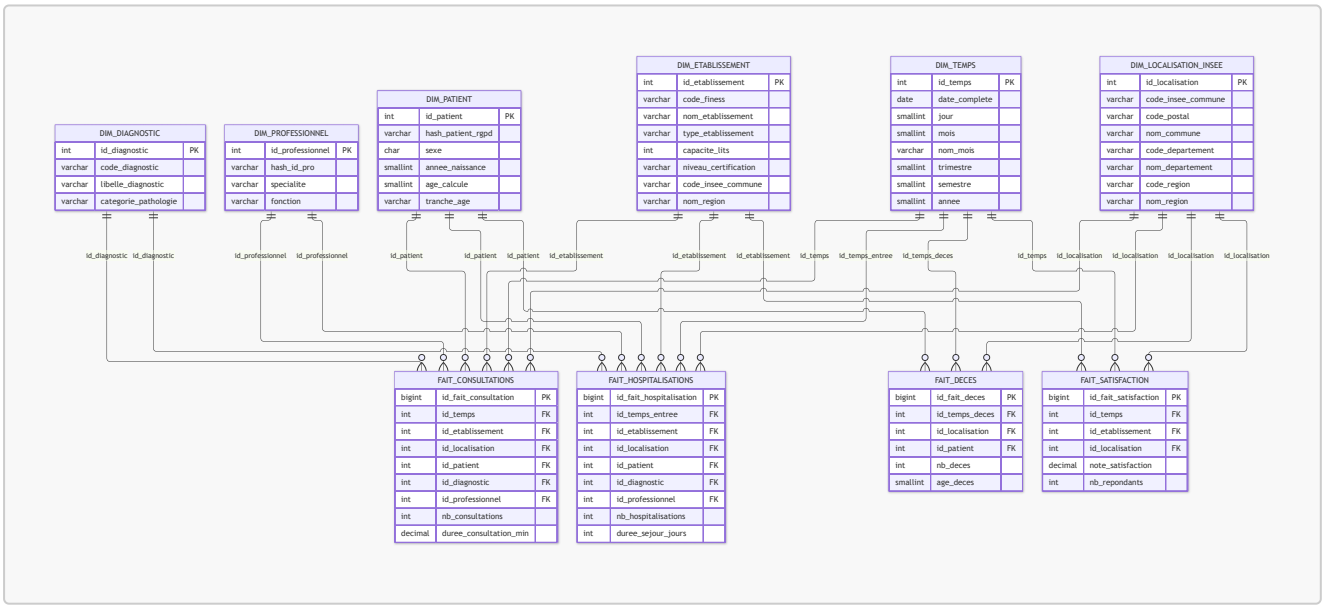
3.1. Méthodologie retenue : Approche Kimball (Constellation d'Étoiles)

L'analyse des besoins utilisateurs met en évidence **4 processus métiers distincts** (les Consultations, les Hospitalisations, la Satisfaction usagers et la Mortalité INSEE) qui n'ont pas la même granularité :

- Une **Consultation** et une **Hospitalisation** ont une granularité fine au niveau de l'*acte patient / professionnel / diagnostic / établissement / jour*.
- La **Satisfaction** est mesurée au niveau *établissement / enquête / période* (sans diagnostic ni professionnel).
- Les **Décès (INSEE)** sont mesurés au niveau *individu décédé / commune-région INSEE / date* (sans établissement hospitalier ni professionnel).

> **Justification du choix de modélisation :**
> Plutôt que de créer une table de faits unique qui contiendrait une majorité de valeurs `NULL` (anti-pattern), nous appliquons la méthodologie **Ralph Kimball** en concevant un **Modèle en Constellation d'Étoiles (Fact Constellation)** composé de **4 Tables de Faits** partageant **6 Tables de Dimensions Conformes** (dénormalisées pour minimiser les jointures `JOIN` et maximiser les performances de lecture OLAP).

3.2. Modèle Logique Global (Schéma en Constellation d'Étoiles)



3.3. Dictionnaire de Données Complet

A. Tables de Dimensions (Axes d'Analyse)

1. Table `DIM_TEMPS` (Calendrier unique partagé)

Nom de l'attribut	Type Logique / Physique	Clé / Contrainte	Cardinalité vers Faits	Description & Règle de gestion
`id_temps`	`INT`	**PK** (`NOT NULL`)	`1..1` → `0..N`	Clé technique au format `AAAAMMJJ` (ex: `20200514`).
`date_complete`	`DATE`	`NOT NULL`	-	Date au standard ISO `YYYY-MM-DD` (compatible Hive/SQL).
`jour`	`SMALLINT`	`NOT NULL`	-	Numéro du jour dans le mois (`1` à `31`).
`mois`	`SMALLINT`	`NOT NULL`	-	Numéro du mois (`1` à `12`).
`nom_mois`	`VARCHAR(20)`	`NOT NULL`	-	Libellé du mois (`Janvier` à `Décembre`).
`trimestre`	`SMALLINT`	`NOT NULL`	-	Numéro du trimestre (`1` à `4`).
`semestre`	`SMALLINT`	`NOT NULL`	-	Numéro du semestre (`1` ou `2`).
`annee`	`SMALLINT`	`NOT NULL`	-	Année sur 4 chiffres (ex: `2019`, `2020`).

2. Table `DIM_LOCALISATION_INSEE` (Référentiel Géographique & Régions)

Nom de l'attribut	Type Logique / Physique	Clé / Contrainte	Cardinalité vers Faits	Description & Règle de gestion
`id_localisation`	`INT`	**PK** (`NOT NULL`)	`1..1` → `0..N`	Clé technique auto-incrémentée (*Surrogate Key*).
`code_insee_commune`	`VARCHAR(10)`	`NOT NULL`	-	Code officiel géographique INSEE de la commune (5 car.).
`code_postal`	`VARCHAR(10)`	`NULL`	-	Code postal associé.
`nom_commune`	`VARCHAR(100)`	`NOT NULL`	-	Nom de la ville / commune.
`code_departement`	`VARCHAR(5)`	`NOT NULL`	-	Numéro de département (`01` à `95`, `2A`, `2B`, `971`...).
`nom_departement`	`VARCHAR(100)`	`NOT NULL`	-	Nom du département.
`code_region`	`VARCHAR(5)`	`NOT NULL`	-	Code INSEE de la région.
`nom_region`	`VARCHAR(100)`	`NOT NULL`	-	**Axe majeur :** Nom de la région (ex: *Auvergne-Rhône-Alpes*).

3. Table `DIM_ETABLISSEMENT` (Hôpitaux et structures de soins — Source 2)

Nom de l'attribut	Type Logique / Physique	Clé / Contrainte	Cardinalité vers Faits	Description & Règle de gestion
`id_etablissement`	`INT`	**PK** (`NOT NULL`)	`1..1` → `0..N`	Clé technique auto-incrémentée.
`code_finess`	`VARCHAR(20)`	`UNIQUE NOT NULL`	-	Identifiant national FINESS de l'établissement.
`nom_etablissement`	`VARCHAR(200)`	`NOT NULL`	-	Raison sociale de l'hôpital / clinique.
`type_etablissement`	`VARCHAR(100)`	`NULL`	-	Catégorie (CHU, CH, Clinique privée, EHPAD...).
`capacite_lits`	`INT`	`DEFAULT 0`	-	Capacité d'accueil en nombre de lits installés.
`niveau_certification`	`VARCHAR(50)`	`NULL`	-	Niveau de certification HAS.
`code_insee_commune`	`VARCHAR(10)`	`NOT NULL`	-	Code INSEE (permet la liaison géographique).
`nom_region`	`VARCHAR(100)`	`NOT NULL`	-	Région dénormalisée pour accélérer les requêtes par établissement.

4. Table `DIM_PATIENT` (Patient anonymisé — Sources 1 & 4)

Nom de l'attribut	Type Logique / Physique	Clé / Contrainte	Cardinalité vers Faits	Description & Règle de gestion
`id_patient`	`INT`	**PK** (`NOT NULL`)	`1..1` → `0..N`	Clé technique interne à l'entrepôt.
`hash_patient_rgpd`	`VARCHAR(64)`	`UNIQUE NOT NULL`	-	Empreinte **SHA-256 salée** de l'ID source (Pseudonymisation RGPD).
`sexe`	`CHAR(1)`	`NOT NULL`	-	Sexe normalisé : `'M'`, `'F'` ou `'I'` (Inconnu).
`annee_naissance`	`SMALLINT`	`NULL`	-	Année de naissance uniquement (jour/mois supprimés pour le RGPD).
`age_calcule`	`SMALLINT`	`NULL`	-	Âge au moment des faits.
`tranche_age`	`VARCHAR(20)`	`NOT NULL`	-	**Généralisation RGPD :** `0-17`, `18-29`, `30-44`, `45-59`, `60-74`, `75+`.

5. Table `DIM_DIAGNOSTIC` (Pathologies — Source 1)

Nom de l'attribut	Type Logique / Physique	Clé / Contrainte	Cardinalité vers Faits	Description & Règle de gestion
`id_diagnostic`	`INT`	**PK** (`NOT NULL`)	`1..1` → `0..N`	Clé technique auto-incrémentée.

Nom de l'attribut	Type Logique / Physique	Clé / Contrainte	Cardinalité vers Faits	Description & Règle de gestion
code_diagnostic	VARCHAR(20)	UNIQUE NOT NULL	-	Code médical de la pathologie (nomenclature CIM-10).
libelle_diagnostic	VARCHAR(255)	NOT NULL	-	Description médicale du diagnostic.
categorie_pathologie	VARCHAR(100)	NULL	-	Famille de pathologie (Cardiologie, Pneumologie, Traumatologie...).

6. Table DIM_PROFESSIONNEL (Praticiens et soignants — Source 1)

Nom de l'attribut	Type Logique / Physique	Clé / Contrainte	Cardinalité vers Faits	Description & Règle de gestion
id_professionnel	INT	**PK** (NOT NULL)	1..1 → 0..N	Clé technique auto-incrémentée.
hash_id_pro	VARCHAR(64)	UNIQUE NOT NULL	-	Identifiant matricule / RPPS pseudonymisé.
specialite	VARCHAR(100)	NOT NULL	-	Spécialité médicale exercée.
fonction	VARCHAR(100)	NULL	-	Catégorie (Médecin, Chirurgien, Infirmier...).

B. Tables de Faits (Mesures et Événements)

1. Table `FAIT_CONSULTATIONS` (Source 1 + Source 2)

- **Granularité :** Une ligne par acte de consultation réalisé.
- **Clé primaire :** `id_fait_consultation` (`BIGINT`) ou clé composite des clés étrangères.
- **Clés étrangères (`NOT NULL`, Cardinalité `0..N` → `1..1`) :** `#id_temps`, `#id_etablissement`, `#id_localisation`, `#id_patient`, `#id_diagnostic`, `#id_professionnel`.
- **Mesures additives :**
  - `nb_consultations` (`INT`, valeur `1` par acte pour sommation `SUM`/`COUNT`).
  - `duree_consultation_min` (`DECIMAL(6,2)`, durée de l'acte en minutes).

2. Table `FAIT_HOSPITALISATIONS` (Source 1 + Source 2)

- **Granularité :** Une ligne par séjour d'hospitalisation.
- **Clés étrangères (`NOT NULL`, Cardinalité `0..N` → `1..1`) :** `#id_temps_entree`, `#id_etablissement`, `#id_localisation`, `#id_patient`, `#id_diagnostic`, `#id_professionnel`.
- **Mesures additives :**
  - `nb_hospitalisations` (`INT`, valeur `1` par séjour).
  - `duree_sejour_jours` (`INT`, calculée via `Date_Sortie - Date_Entree` dans l'ETL).

3. Table `FAIT_SATISFACTION` (Source 3 + Source 2)

- **Granularité :** Une ligne par évaluation de satisfaction d'un établissement sur une période.
- **Clés étrangères (`NOT NULL`, Cardinalité `0..N` → `1..1`) :** `#id_temps`, `#id_etablissement`, `#id_localisation`.
- **Mesures :**
  - `note_satisfaction` (`DECIMAL(5,2)`, score sur 100 ou sur 10 — semi-additif : agrégé par moyenne `AVG`).
  - `nb_repondants` (`INT`, nombre de questionnaires exprimés — additif `SUM`).

4. Table `FAIT_DECES` (Source 4 : Open Data INSEE)

- **Granularité :** Une ligne par décès déclaré en France (ou pré-agrégé par jour/commune/sexe/tranche d'âge).
- **Clés étrangères (`NOT NULL`, Cardinalité `0..N` → `1..1`) :** `#id_temps_deces`, `#id_localisation`, `#id_patient` (profil démographique sexe/tranche d'âge).
- **Mesures :**
  - `nb_deces` (`INT`, valeur `1` par décès enregistré — additif `SUM`).
  - `age_deces` (`SMALLINT`, âge au moment du décès — agrégé par moyenne `AVG`).

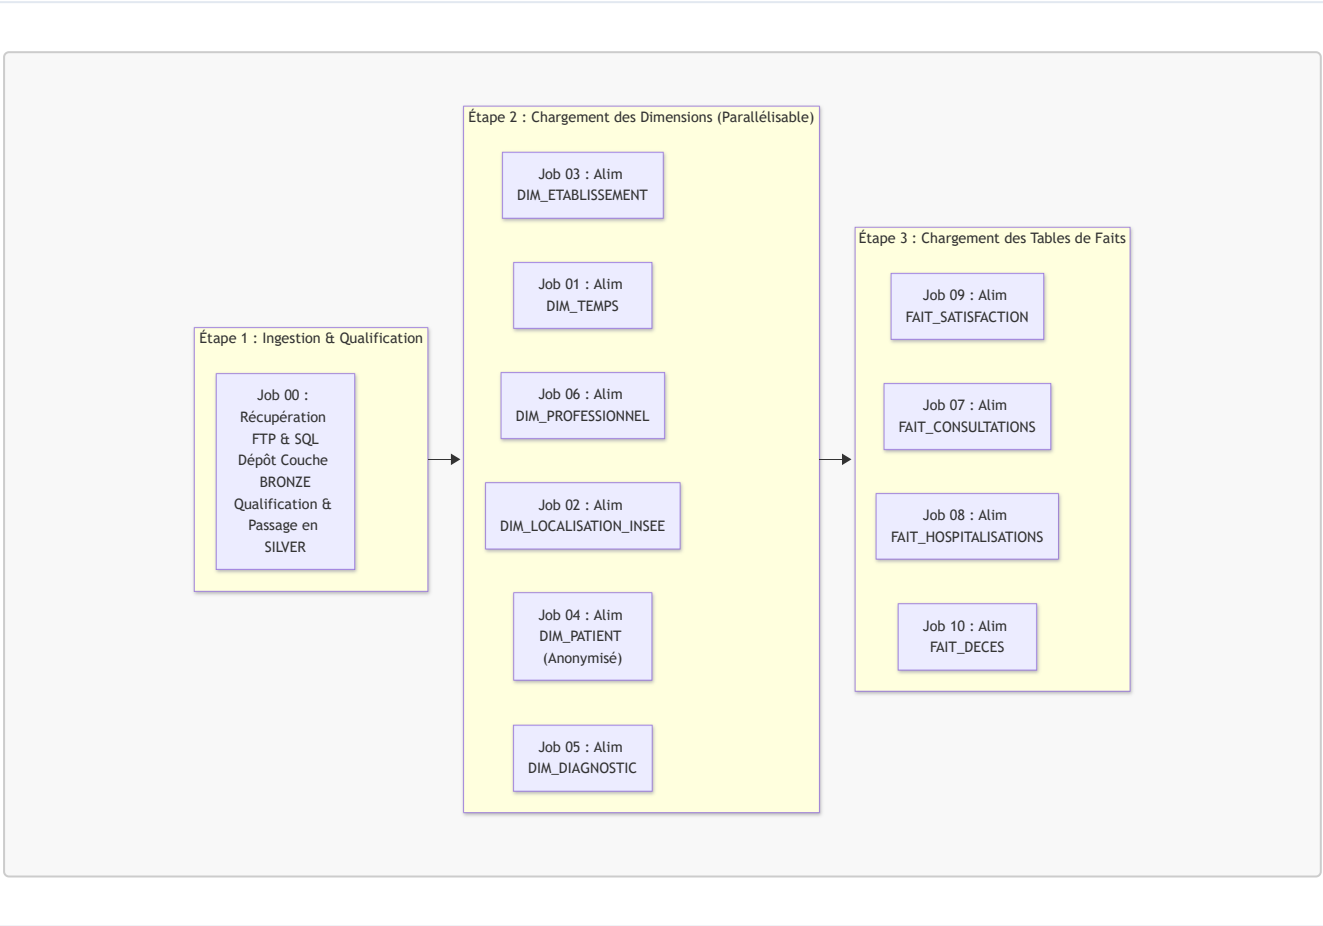
3.4. Matrice de Couverture des Indicateurs Métiers

Besoin Utilisateur (Cahier des Charges)	Table de Faits sollicitée	Dimensions jointes (`JOIN`)	Formule Analytique SQL / BI
1. Taux de consultation dans un établissement X sur période Y	`FAIT_CONSULTATIONS`	`DIM_ETABLISSEMENT`, `DIM_TEMPS`	`SUM(nb_consultations) / Total_Consultations_Periode * 100`
2. Taux de consultation par diagnostic X sur période Y	`FAIT_CONSULTATIONS`	`DIM_DIAGNOSTIC`, `DIM_TEMPS`	`SUM(nb_consultations) [Diag X] / Total_Consultations_Periode * 100`
3. Taux global d'hospitalisation sur une période Y	`FAIT_HOSPITALISATIONS`	`DIM_TEMPS`	`SUM(nb_hospitalisations) / Population_Patients_Actifs * 100`
4. Taux d'hospitalisation par diagnostic sur période Y	`FAIT_HOSPITALISATIONS`	`DIM_DIAGNOSTIC`, `DIM_TEMPS`	`SUM(nb_hospitalisations) [Diag X] / Total_Hospit_Periode * 100`
5. Taux d'hospitalisation par sexe et par âge	`FAIT_HOSPITALISATIONS`	`DIM_PATIENT` (`sexe`, `tranche_age`)	`SUM(nb_hospitalisations)` groupé par `sexe` et `tranche_age`
6. Taux de consultation par professionnel	`FAIT_CONSULTATIONS`	`DIM_PROFESSIONNEL`	`SUM(nb_consultations)` groupé par `id_professionnel` / `specialite`
7. Nombre de décès par région sur l'année 2019	`FAIT_DECES`	`DIM_LOCALISATION_INSEE`, `DIM_TEMPS`	`SUM(nb_deces)` avec `WHERE annee = 2019 GROUP BY nom_region`
8. Taux global de satisfaction par région sur l'année 2020	`FAIT_SATISFACTION`	`DIM_LOCALISATION_INSEE`, `DIM_ETABLISSEMENT`, `DIM_TEMPS`	`AVG(note_satisfaction)` pondéré par `nb_repondants` (`WHERE annee = 2020`)

4. Spécifications Fonctionnelles des Jobs ETL

4.1. Architecture d'Alimentation et Ordonnancement

Afin de garantir l'intégrité référentielle dans la couche Gold (Apache Hive / PostgreSQL), l'orchestration des jobs ETL sous **Talend Open Studio** suit un séquencement strict en **3 phases** :



4.2. Règles de Transformation, Formatage et Enrichissement

ID Règle	Champ / Flux concerné	Problématique Source	Règle de Transformation Fonctionnelle (Composant Talend `tMap`)
RT-01	**Enrichissement Régional** (Sources 1, 2, 3, 4)	La région n'est pas directement présente dans les tables d'actes ou d'établissements.	Jointure (*Lookup*) sur le `code_insee` ou les 2 premiers caractères du `code_postal` avec le référentiel officiel INSEE des communes/départements/régions pour injecter `nom_region`.
RT-02	**Normalisation des Dates** (Toutes les sources)	Formats hétérogènes (`DD/MM/YYYY`, `YYYYMMDD`, texte) incompatibles avec Hive.	Conversion systématique au format ISO `YYYY-MM-DD` via `TalendDate.parseDate()` et génération de la clé entière `id_temps = AAAAMMJJ`.

ID Règle	Champ / Flux concerné	Problématique Source	Règle de Transformation Fonctionnelle (Composant Talend `tMap`)
RT-03	**Pseudonymisation & Âge** (`DIM_PATIENT`)	Présence de Nom, Prénom, Date de naissance exacte et NIR dans PostgreSQL / INSEE.	1. Suppression des colonnes `Nom`, `Prenom`, `Adresse`, `NIR`. 2. Hachage salé de l'ID : `SHA256(id_patient_source + sel_secret)`. 3. Calcul de l'âge et affectation dans `tranche_age` (`0-17`, `18-29`, `30-44`, `45-59`, `60-74`, `75+`).
RT-04	**Harmonisation du Sexe** (`DIM_PATIENT`)	Codage disparate (`1`/`2` dans INSEE, `H`/`F` ou `M`/`F` dans PostgreSQL).	Transcodification via `tReplace` / `tMap` : `'1'` ou `'H'` → `'M'` ; `'2'` ou `'F'` → `'F'` ; sinon `'I'`.
RT-05	**Calcul Durée de Séjour** (`FAIT_HOSPITALISATIONS`)	Seules les dates d'entrée et de sortie sont présentes dans PostgreSQL.	Calcul : `TalendDate.diffDate(date_sortie, date_entree, "dd")`. Si la sortie a lieu le même jour (ambulatoire), forcer `duree_sejour_jours = 1`.
RT-06	**Normalisation Code FINESS** (`DIM_ETABLISSEMENT`)	Codes FINESS parfois sur 8 caractères (zéro initial tronqué par CSV/Excel).	Formatage `StringHandling.LPAD(code_finess, 9, "0")` et `TRIM()` pour garantir la jointure exacte entre PostgreSQL, le CSV Établissements et le FTP Satisfaction.

4.3. Gestion des Valeurs Nulles, des Doublons, des Erreurs et des Rejets

1. **Gestion des Doublons (Unicité) :**
   - Utilisation systématique du composant **`tUniqRow`** sur les clés naturelles avant insertion dans les dimensions (`code_finess` pour Établissement, `code_diagnostic` pour Diagnostic, `hash_patient_rgpd` pour Patient, `id_acte` pour les Consultations/Hospitalisations).
2. **Gestion des Valeurs Nulles (Complétude) :**
   - **Clés étrangères manquantes dans les faits :** Si une consultation fait référence à un diagnostic ou à un établissement non renseigné (`NULL`) ou absent du référentiel, on ne supprime pas l'acte médical (ce qui fausserait le volume global de consultations !). On le rattache à une **ligne technique par défaut** créée dans chaque dimension avec `id = -1` et libellé `'Non renseigné / Inconnu'`.
   - **Mesures nulles :** Remplacement des notes ou durées nulles par la valeur par défaut ou rejet si l'enregistrement est totalement corrompu.
3. **Gestion des Erreurs et Table des Rejets :**
   - Dans chaque composant `tFileInputDelimited` et `tMap`, le flux **`Rejects`** **(Rejets)** est activé.
   - Toute ligne présentant une erreur de format critique (ex: date de sortie antérieure à la date d'entrée, note de satisfaction négative ou `> 100`, ligne CSV mal formée) est déroutée vers un répertoire dédié `/datalake/rejects/YYYYMMDD_nom_job_rejets.csv` avec le code et le motif de l'erreur (`errorCode`, `errorMessage`), accompagné d'une alerte dans les logs (`tLogCatcher`).

4.4. Planification et Fréquence d'Exécution des Flux

Flux / Job ETL	Source concernée	Mode de chargement	Fréquence d'exécution	Fenêtre de tir (Batch)
Ingestion & Mise à jour Actes	Source 1 (PostgreSQL)	Incrémental (Delta sur date d'acte)	**Quotidienne (J+1)**	Tous les soirs à `01h00` (heures creuses).

Flux / Job ETL	Source concernée	Mode de chargement	Fréquence d'exécution	Fenêtre de tir (Batch)
Mise à jour Référentiel FINESS/INSEE	Source 2 (Fichiers CSV)	Complet / SCD Type 1 (Écrasement / Ajout)	**Mensuelle**	Le 1er du mois à `00h30`.
Intégration Enquêtes Satisfaction	Source 3 (FTP)	Incrémental par campagne	**Mensuelle / Trimestrielle**	Dès détection d'un nouveau fichier sur le FTP.
Intégration Décès Open Data INSEE	Source 4 (FTP)	Incrémental mensuel / annuel	**Mensuelle**	Le 5 de chaque mois à `03h00`.

5. Plan de Gouvernance des Données et Sécurité (RGPD & HDS)

Le traitement de données issues du secteur hospitalier soumet le projet CHU à une double obligation légale : le **RGPD (Article 9 relatif aux données concernant la santé)** sous le contrôle de la **CNIL**, et le **Code de la santé publique (Article L.1111-8)** imposant la certification **HDS**.

5.1. Conformité RGPD : Minimisation, Pseudonymisation et Anonymisation

Nous appliquons le principe de **Privacy by Design** (Protection des données dès la conception) à travers 4 mesures techniques implémentées dès le passage de la couche Bronze à la couche Silver :

1. **Minimisation stricte des données (Art. 5.1.c du RGPD) :**
    - L'entrepôt décisionnel a une finalité purement statistique et analytique. Par conséquent, **aucun attribut directement identifiant** (Nom de naissance, Nom d'usage, Prénom, Numéro de Sécurité Sociale / NIR, Adresse postale exacte, Téléphone, Email) n'est transféré dans les couches Silver et Gold.
2. **Pseudonymisation irréversible par hachage salé (Art. 32 du RGPD) :**
    - Afin de pouvoir calculer le taux de ré-hospitalisation ou le nombre de consultations par patient unique sans connaître son identité, l'identifiant patient source est transformé par une fonction de hachage cryptographique **SHA-256** combinée à un sel secret (*Salt*) détenu uniquement par le serveur ETL sécurisé.
3. **Généralisation pour prévenir la ré-identification indirecte (*K-Anonymat*) :**
    - La date de naissance complète (`JJ/MM/AAAA`) est réduite à l'**année de naissance** et convertie en **tranche d'âge** (`0-17`, `18-29`, etc.).
    - L'adresse du patient est généralisée au niveau du **Département / Région**.
4. **Durée de conservation limitée et Droit à l'effacement :**
    - Les fichiers bruts déposés dans la couche **Bronze** (qui contiennent encore les extractions brutes avant passage de l'ETL) sont purgés automatiquement après **7 jours** une fois la validation de chargement en couche Silver confirmée.
    - Les données anonymisées/pseudonymisées des couches Silver et Gold sont conservées pour une durée maximale de **10 ans** à des fins d'études épidémiologiques et de pilotage historique.

5.2. Conformité HDS (Hébergeur de Données de Santé) et Sécurité Infrastructure

- **Hébergement certifié HDS :** L'infrastructure cible (serveurs physiques ou Cloud privé/public hébergeant PostgreSQL, le serveur FTP et le cluster Cloudera Hadoop) doit obligatoirement être opérée par un hébergeur disposant de la certification **HDS (ISO 27001 + exigences santé françaises)** et localisé au sein de l'**Union Européenne** (immunité face aux lois extraterritoriales type *Cloud Act*).
- **Chiffrement de bout en bout :**
    - **Chiffrement en transit (*In-Transit*) :** Flux FTP remplacés par du **SFTP (SSH File Transfer Protocol)** ou **FTPS (TLS 1.3)** ; connexions JDBC PostgreSQL et Hive chiffrées en SSL/TLS.
    - **Chiffrement au repos (*At-Rest*) :** Activation du chiffrement transparent des blocs HDFS (*HDFS Transparent Encryption - KMS*) et des volumes disques (AES-256).

5.3. Gestion des Rôles et Droits d'Accès (Matrice RBAC)

L'accès aux différentes couches de l'architecture est verrouillé selon le **principe du moindre privilège** (*Role-Based Access Control* — RBAC) :

Profil / Rôle	Couche BRONZE (Brut)	Couche SILVER (Propre)	Couche GOLD (Hive Data Mart)	Tableaux de Bord Power BI
Compte de Service ETL (Talend)	Lecture / Écriture	Lecture / Écriture	Écriture (Insertion)	Aucun accès
Data Engineer / Admin BDD	Administration technique	Lecture / Écriture	Administration DDL/DML	Administration technique
DPO (Délégué Protection Données)	Audit & Contrôle	Audit & Contrôle	Audit & Contrôle	Audit de conformité
Praticiens (Médecins / Infirmiers)	**Interdit**	**Interdit**	Accès direct interdit	**Lecture seule :** Indicateurs médicaux, diagnostics, âge/sexe, mortalité.
Direction d'Établissement	**Interdit**	**Interdit**	Accès direct interdit	**Lecture seule :** Indicateurs d'affluence, taux d'hospitalisation, satisfaction.

5.4. Traçabilité des Flux (Data Lineage) et Cycle de Vie des Données

Afin d'assurer l'auditabilité complète de l'entrepôt décisionnel :

1. **Métadonnées techniques d'audit dans chaque table :** Chaque table du Data Mart intègre deux colonnes techniques d'audit : `date_chargement_etl` (`TIMESTAMP`) et `source_fichier_origine` (`VARCHAR`) permettant de savoir exactement quand et par quel job une ligne a été insérée.
2. **Journalisation centralisée (*Logging*) :** Chaque exécution de job Talend génère un journal d'exécution (`nb_lignes_lues`, `nb_lignes_inserees`, `nb_lignes_rejetees`, `duree_execution`, `statut_job`) historisé dans une table de suivi technique `TECH_ETL_LOGS`.
3. **Journalisation des accès utilisateurs :** Toute connexion et requête effectuée sur l'entrepôt Hive ou sur les rapports Power BI est tracée (horodatage, identifiant de l'utilisateur) conformément aux exigences de traçabilité HDS.

Conclusion

En conclusion, ce premier livrable pose les fondations du projet décisionnel du CHU en définissant une architecture complète, moderne et conforme aux contraintes du sujet.

Trois choix structurants :

- **Une architecture scalable et évolutive :** Le Data Lakehouse en architecture Médaillon (Bronze / Silver / Gold) sur cluster Cloudera Hadoop (HDFS + Hive) offre un socle distribué, robuste et prêt pour le volume de données. La logique ELT / ETL hybride, orchestrée via Talend Open Studio, garantit des flux de données fiables et auditables.
- **Un modèle dimensionnel :** La constellation d'étoiles conforme à la méthodologie Kimball avec 4 tables de faits ainsi que 6 tables de dimensions. Cela évite l'anti-pattern de la table de faits unique creuse, tout en maximisant les performances OLAP et en garantissant l'intégrité référentielle dans la couche Gold.
- **Une conformité réglementaire native :** Le traitement de données de santé impose l'exigence RGPD et la certification HDS.

En synthèse, ce référentiel de données constitue le contrat de base sur lequel les livrables suivants pourront s'appuyer : la validation de cette architecture et de ce modèle dimensionnel débloque la phase d'implémentation des flux ETL, des scripts Hive et de l'exploitation analytique en couche Gold (Hive / PostgreSQL), avec l'assurance que la solution sera à la fois performante, maintenable et légalement conforme.